

Análisis de Rendimiento de Publicaciones en Facebook: un Proyecto con Python y SQL

Contexto

Soy egresado de la Licenciatura en Matemáticas y administro una página de Facebook con más de 70,000 seguidores, en la que publico principalmente contenido audiovisual. El objetivo de este proyecto es entender y maximizar el rendimiento de esas publicaciones, en particular las de video.

Mi objetivo principal era relativamente sencillo: quería responder preguntas concretas sobre mi contenido, como qué día de la semana y a qué hora era mejor publicar, si había palabras particulares que se repetían más en mis descripciones, y cuáles eran mis videos más vistos. No buscaba un análisis excesivamente complejo, aproveché este tipo de preguntas prácticas como pretexto para desarrollar el proyecto y reforzar mis habilidades técnicas.

Previamente había desarrollado un proyecto de análisis de datos en Python, y consideré que esta era una buena oportunidad para ampliar ese trabajo incorporando SQL, y más adelante, Power BI.

Como parte de este proceso, también me interesa aprovechar herramientas de inteligencia artificial (Claude, ChatGPT y Gemini) como apoyo de trabajo, con el fin de agilizar el desarrollo técnico y optimizar tiempo y recursos.

Trabajo realizado por:

Armando Hernández Sayago

Lic. en Matemáticas | UAM Iztapalapa

Índice

- Contexto — 1
- Herramientas utilizadas — 3
- Sobre los datos — 3
- Pasos realizados — 3
- Hallazgos — 5
- Consultas SQL — 9
- Conclusiones Generales — 14
- Próximos pasos — 14
- Enlaces y proyectos relacionados — 15

Herramientas utilizadas

- **Python** — extracción y limpieza de datos
- **SQL (SQLite)** — modelado y consultas
- **IA's** (Claude, ChatGPT, Gemini) — apoyo en la generación de código y resolución de dudas técnicas
- **Power BI** — visualización (en un futuro)

Sobre los datos

Los datos utilizados corresponden a las publicaciones de mi página de Facebook, descargados el 10 de marzo de 2026. Abarcan publicaciones realizadas entre el 11 de marzo de 2025 y el 10 de marzo de 2026, con un total de **653 publicaciones**.

Pasos realizados

1. Exploración inicial (Python)

Se cargó el archivo crudo descargado de Facebook y se revisó su estructura general: 653 filas (publicaciones) y 317 columnas. Con apoyo de ChatGPT¹ en esta etapa inicial, identifiqué que la gran mayoría de esas columnas correspondían a desgloses poco relevantes para mi análisis. Al desglosarlas:

- **~64 columnas núcleo** — identificadores, fecha, título, descripción, métricas de alcance e interacción
- **159 columnas** de reproducciones de video desglosadas por país
- **82 columnas** de la curva de retención de video
- **12 columnas** de desglose demográfico (género y edad)

2. Reconocimiento y selección de columnas

Tras visualizar el contenido de las columnas, evalué cuáles aportaban valor para las preguntas de mi proyecto (rendimiento de video, hora de publicación, retención, palabras en las descripciones) y cuáles no. En esta etapa me apoyé en Claude para obtener orientación sobre qué columnas podrían ser útiles en consultas futuras. Con base en esto, decidí no utilizar las columnas de país ni de demografía, pero sí conservar las de retención de video, y seleccioné las columnas núcleo relevantes para proceder con la limpieza.

¹ Consulte en GitHub la carpeta "Códigos" - Python

3. Limpieza y generación de tablas (Python)

Con ayuda de Claude, quien generó el código en Python para llevar a cabo la limpieza y transformación de los datos, obtuve tres tablas principales, pensadas para responder al objetivo del proyecto.

- ``posts_clean`` — una fila por publicación, con la información núcleo ya limpia (fecha, hora, tipo de publicación, métricas de alcance e interacción)
- ``retencion_video`` — la curva de retención de video, reorganizada de formato ancho (82 columnas) a formato largo (una fila por cada punto de la curva)
- ``top_palabras`` — frecuencia de palabras utilizadas en las descripciones de mis publicaciones

4. Creación de la base de datos y consultas (SQL)

Con esas tres tablas limpias, diseñé un esquema y creé una base de datos en SQLite² (usando DB Browser for SQLite como interfaz), sobre la cual empecé a correr las consultas de análisis.

Durante este proceso comencé a notar inconsistencias en los datos que no eran evidentes a simple vista, particularmente en la tabla de retención de video. Esto me llevó a investigar más a fondo, apoyándome nuevamente en Claude para formular hipótesis y comprobarlas contra mis propios datos en vez de darlas por ciertas. Nos dimos cuenta de muchas cosas curiosas que no estaban documentadas de forma explícita por Facebook. A continuación documento esos hallazgos.

² Consulte en GitHub la carpeta “Códigos” - SQL

Hallazgos

Hallazgo 1 — El cálculo teórico (653×82) parte de un supuesto falso

53,546 asume que todas las publicaciones tienen datos completos de retención. Eso no es cierto: la retención de video solo existe para contenido audiovisual. De las 653 publicaciones, la distribución real por tipo es:

...

Videos	280
Fotos	228
Reels	81
Texto	49
En vivo	13
Enlaces	2

...

Solo Videos + Reels = 361 son candidatos plausibles a tener retención.

Hallazgo 2 — Ni siquiera todos los videos reales tienen retención

De los 280 posts tipo "Videos", 22 no generaron ningún dato de retención. Al comparar su alcance contra los que sí tienen retención:

	Videos SIN retención (22)	Videos CON retención (258)
Alcance promedio	1,238	59,815

La diferencia es de ~48x. La hipótesis (razonable, no confirmada oficialmente) es que Facebook no calcula/publica la curva de retención por debajo de cierto umbral de vistas.

Hallazgo 3 — 37 publicaciones “mal clasificadas” también traen datos de retención

Aparecieron 37 publicaciones etiquetadas como Texto, Fotos o En vivo con datos de retención, que en teoría no deberían tenerlos. Al revisar sus títulos y duración:

- **25 son Texto/Fotos con `duracion\_segundos = 0`**, con títulos como “Ya andamos en vivo, manden sus saludos!” — muy probablemente anuncios ligados a una transmisión en vivo, mal clasificados en el export de Meta.

- **12 son "En vivo" con duración real** (ej. 1912, 2014, 2907 segundos) transmisiones legítimas que sí generan retención propia, sin ningún error.

Hallazgo 4 — El total real: 376 publicaciones con retención

361 (Videos + Reels) - 22 (sin suficiente audiencia) + 37 (casos extra) = **376**, que coincide exactamente con ``retencion_video[id_publicacion].nunique()``. La coincidencia entre el número calculado y el medido fue la evidencia de que la explicación estaba completa.

Recomendación práctica: al filtrar videos, usar ``id_publicacion.isin(ids_con_retencion)`` en vez de ``tipo_publicacion == "Videos"``, ya que la segunda etiqueta no es 100% confiable.

Hallazgo 5 — Qué son los 41 intervalos (0 a 40): la resolución depende de la duración del video³

Este hallazgo fue revisado: una primera versión asumía bloques fijos de 4 segundos para todo video. Al inspeccionar el CSV crudo columna por columna para un video de 33 segundos, se encontró que los 37 intervalos (0 al 36) tienen valores reales y distintos, no solo cada 4. La resolución real es mucho más fina de lo que se había asumido.

Conclusión corregida:

- **Videos de hasta ~40 segundos:** cada intervalo corresponde a **1 segundo real** de reproducción acumulada. Los datos se detienen en el siguiente punto múltiplo de 4 después del fin del video (por ejemplo, un video de 33s reporta hasta el intervalo 36, no el 33 exacto) posiblemente por el mismo efecto de reproducción en bucle ya documentado en videos muy cortos.
- **Videos de más de 40 segundos:** cada intervalo se escala para que el video completo quepa en los 41 puntos disponibles, aproximadamente **duración ÷ 40** segundos por intervalo. Confirmado con un método de calibración independiente (usando los segundos promedio reproducidos como referencia): error típico x1.13 con el modelo escalado, contra x1.56 si se asumiera un eje fijo de segundos reales sin escalar.

³ Consulte en GitHub la carpeta "Códigos" - Python

Hallazgo 6 — Diferencia entre "general" y "15 segundos"

No son mediciones anidadas ni con distinta resolución de tiempo entre sí, **ambas usan el mismo eje de tiempo** (la resolución de ese eje depende de la duración del video, según el Hallazgo 5, pero es la misma para "general" y "15 segundos" dentro de un mismo video). Lo que cambia es quién cuenta como el "100% inicial":

- **General:** 100% = todas las personas que le dieron play, incluyendo quien se salió de inmediato.
- **15 segundos:** 100% = solo quienes acumularon al menos 15 segundos vistos en total (sin importar si lo hicieron de corrido o con pausas/saltos). Este grupo se define una sola vez, viendo la sesión completa ya terminada, no se recalcula punto a punto.

Comprobación adicional: al normalizar ambas curvas desde el primer punto donde pueden mostrar caída real, la curva "15 segundos" decae consistentemente más lento que la general en todos los tramos, no solo arranca más arriba. Esto indica que el público que supera el "gancho" inicial de 15 segundos es genuinamente más leal en el resto del video, no solo un subconjunto desplazado de la misma curva.

Hallazgo 7 — Por qué hay pequeñas variaciones (1-3%) antes del punto que marca los 15 segundos reales

El grupo "15 segundos" se define sobre el total de la sesión, así que antes de ese punto es lógicamente casi imposible que alguien del grupo ya se haya ido, de haberse ido antes, no habría calificado para el grupo. Por eso la curva se mantiene prácticamente plana hasta ahí, y es justo después de ese punto donde empieza la caída genuina, con un patrón de decaimiento suave y continuo (caída fuerte al inicio, cola cada vez más plana) no hay saltos periódicos ni reinicios cada 15 segundos, ya que se trata de un único grupo fijo medido a lo largo de todo el video.

Aun así, existen pequeñas variaciones incluso antes de ese punto, por dos causas distintas según el tamaño de audiencia del video:

- **Audiencias muy chicas** (casos dentro de las 37 publicaciones del Hallazgo 3, algunas con apenas 3-20 espectadores): la variación es aritmética pura, no ruido de medición. Con un grupo de 20 personas, el porcentaje solo puede moverse de 5% en 5% (1/20), perder a un par de personas reales produce saltos grandes, sin que haya ningún error de conteo.

- **Audiencias grandes** (ej. un video de 195s con 44,966 reproducciones): aquí un 1% ya representa ~450 personas, demasiado para ser ruido de muestra chica. La explicación es que no todos los que acumulan 15 segundos vistos lo hacen de corrido: alguien puede pausar, saltar con la barra de reproducción, o salir y volver, acumulando sus 15 segundos de forma no continua.

Hallazgo 8 — Un grupo de 22 videos con metadatos incompletos

Al investigar por qué ciertos videos mostraban ``duracion_segundos = 0``, se confirmó que se trata exactamente del mismo grupo de 22 videos del Hallazgo 2 (sin datos de retención), no es una coincidencia, es la misma anomalía de metadatos incompletos vista desde dos ángulos distintos. Recomendación: excluir este grupo (``duracion_segundos > 0``) en cualquier consulta que dependa de la duración del video.

Conclusión general de Hallazgos

La discrepancia inicial (22,266 filas en la tabla de retención, en vez de las 53,546 esperadas por el cálculo teórico) se explica por tres reducciones sucesivas, no todas las publicaciones son video, no todos los videos generan retención, y no todos los que generan retención llegan a los 82 puntos completos, más una corrección (37 publicaciones mal clasificadas que sí traían datos). Cada paso de esta explicación fue verificado contra los datos reales, no asumido.

Consultas SQL

En este apartado se muestran las preguntas (consultas) que se plantearon durante el análisis, junto con su resultado. El código SQL de cada consulta no se incluye aquí, se puede consultar en el repositorio de GitHub del proyecto, en la carpeta destinada exclusivamente al código⁴.

Vale la pena recordar que se trabajó sobre una base de datos en SQLite compuesta por tres tablas: posts, retencion_video y top_palabras.

1. ¿Qué combinación de día de la semana y hora de publicación genera mejor desempeño en mis videos?⁵

1

día_semana	hora_publicacion	num_videos	promedio_reproducciones_3s
Friday	18	7	28441.0
Friday	19	5	9566.0
Monday	18	7	10849.0
Monday	19	17	46643.0
Monday	20	6	5029.0
Saturday	19	8	23914.0
Saturday	20	5	13014.0
Sunday	18	5	15745.0
Thursday	17	7	21122.0

El resultado es contundente: **martes a las 17:00 (5pm)** tiene un promedio de 282,311 reproducciones, muy por encima de cualquier otra combinación (la segunda más alta es martes a las 18:00, con 140,315, y después todo baja a rangos de 9,000-46,000). El martes en general es el mejor día: aparece con buen desempeño en varias horas seguidas (5pm, 6pm, 7pm).

Para el lado de "cuándo no publicar": los peores resultados son **lunes a las 20:00** (5,029) y **viernes a las 19:00** (9,566), interesante que incluso el martes, el mejor día, cae fuerte a las 20:00 (9,446), como si el impulso del día se agotara después de las 7pm.

⁴ Consulte en GitHub la carpeta "Códigos" - SQL

⁵ Por optimización de espacio, las tablas no se muestran de manera completa.

2a. ¿Cómo es la curva de retención, segundo a segundo, de mis videos de hasta 40 segundos de duración?

2a

tipo_retencion	segundo	num_videos	retencion_promedio_pct
15_segundos	0	111	99.9
15_segundos	1	111	99.9
15_segundos	2	111	99.9
15_segundos	3	111	100.0
general	40	11	18.7

La audiencia general se decide muy rápido: de 99% al inicio cae a 59% en apenas 8 segundos, es decir, **casi la mitad del público decide si se queda o se va en los primeros 8 segundos**. La curva de "15 segundos" se mantiene casi plana hasta el segundo 16 (como es lógico, por definición), y de ahí en adelante cae más lento que la general, terminando en 37% hacia el segundo 40 (contra 19% de la general). Confirma lo que ya sabíamos: el gancho inicial es crítico, pero quien lo supera, se queda notablemente más tiempo.

2b. ¿Cómo es la curva de retención, por porcentaje de avance del video, en mis videos de más de 40 segundos de duración?

2b

tipo_retencion	pct_del_video	num_videos	retencion_promedio_pct
15_segundos	0.0	147	99.7
15_segundos	2.5	147	99.6
15_segundos	5.0	147	98.9
15_segundos	7.5	147	97.0

Aquí la caída inicial es todavía más agresiva en términos relativos: para apenas el 10% de avance del video, la audiencia general ya bajó a 58.6%; para el 25% del video, solo queda un 31.3%. La curva de "15 segundos" cae mucho más despacio, por ejemplo, a la mitad del video (50%) todavía conserva al 51.2% de su público, casi el triple que el 17.4% de la audiencia general en ese mismo punto. Al final del video, sobrevive el 23.8% de los que superaron el gancho, contra solo 7.4% del total. Conclusión práctica: en los videos largos, el tramo más crítico para retener gente es literalmente el arranque, quien aguanta ese primer tramo, tiende a quedarse hasta el final.

3. ¿Qué palabras se repiten con mayor frecuencia en las descripciones de mis publicaciones?

3

palabra	frecuencia
rock	496
sonideros	293
rocknroll	292
lospuercosdelrock	274
rnrr	156

Dominan las palabras de género musical y marca ("rock", "rocknroll", "rockandroll", "rnrr", "lospuercosdelrock", "rockeros") junto con nombres de lugares donde trabajo ("ciudadneza", "chimalhuacan", "valledechalco"). Al final aparece un grupo de palabras de contacto/promoción ("https", "whatsapp", "directo").

4. ¿Cómo se compara el desempeño entre los distintos tipos de contenido que publico (video, foto, reel, texto, en vivo)?

4

tipo_publicacion	num_publicaciones	alcance_promedio	interaccion_promedio
Videos	280	55213.0	1973.8
Reels	81	37503.0	1195.4
En vivo	13	10170.0	358.0
Fotos	228	4618.0	91.6
Enlaces	2	2967.0	59.5
Texto	49	1383.0	45.2

Video es el mejor formato por mucho: 55,213 de alcance promedio y 1,974 de interacción, más del doble que Fotos (4,618 / 92) y muy por encima incluso de Reels (37,503 / 1,195). Confirma con datos que enfocar el análisis en video fue la decisión correcta.

5. ¿La duración de un video influye en su desempeño?

5

rango_duracion	num_videos	promedio_reproducciones_3s	promedio_comentarios
1) < 30s	83	60785.0	80.7
2) 30-60s	81	37262.0	88.0
3) 1-3 min	76	30913.0	106.7
4) 3+ min	18	15805.0	38.9

Aquí hay una divergencia interesante: entre más corto el video, más reproducciones consigue (60,785 en <30s, bajando de forma constante hasta 15,805 en 3+ min) pero los comentarios no siguen ese mismo patrón: **pican en 1-3 minutos (106.7)**, por encima de los videos cortos (80.7). Es decir, los videos cortos ganan en alcance, pero los de duración media generan más conversación.

6a. ¿Cuáles son mis 10 videos con mejor desempeño?

6a

titulo	fecha_hora_publicaci	hora_p	duracion_seg	reproducciones_3s	comentarios	alcance
Oh no! 😞	2025-10-14 18:19:00	18	11.0	2083288.0	2885.0	2378305.0
Sacando los pas	2025-11-11 17:34:00	17	50.0	1652396.0	4456.0	2262596.0
Chalco es Rocka WhatsApp Direct	2026-01-18 14:59:00	14	14.0	1288179.0	2491.0	1644040.0
Así es como la b	2025-04-08 19:24:00	19	109.0	574999.0	3804.0	963227.0
x: Vete con la roc	2025-07-17 19:08:00	19	61.0	367829.0	750.0	693193.0

Con esta consulta respondo directamente una de las preguntas que planteé al inicio del proyecto: cuáles son mis videos más vistos. Mi video con más reproducciones es "Oh no! 😞", con 2,083,288 reproducciones y 2,378,305 de alcance, en apenas 11 segundos de duración. Curiosamente, el video con más comentarios (4,456) no es el más visto, sino "Sacando los pasitos Trisoleros...", que queda en segundo lugar. También noto que casi todos mis videos top son cortos (11, 14, 15, 7 segundos), coincide con lo que ya había encontrado en la pregunta 7, donde los videos cortos generan más reproducciones.

Conclusiones Generales

Este proyecto me permitió comprobar que sí se puede trabajar de forma sólida tanto con Python como con SQL, incluso partiendo de datos crudos con bastante ruido, como los que descarga Facebook. Uno de los aspectos que más valoro de todo el proceso es la sección de Hallazgos: más allá de resolver dudas puntuales, esa investigación me sirvió para verificar que todo el proceso de limpieza, transformación y modelado de datos estaba bien fundamentado, no me quedé con la primera explicación que parecía razonable, sino que la comprobé contra los datos reales antes de darla por buena.

Las consultas SQL, por su parte, me sirvieron principalmente para confirmar con evidencia cosas que ya sospechaba de forma intuitiva, sin haberlas analizado formalmente, por ejemplo, que el martes es uno de mis mejores días para publicar, o que mis videos cortos tienden a funcionar mejor. En este documento no incluí la totalidad de las consultas que realicé, solo una selección de las más relevantes, para no hacerlo demasiado extenso (el resto del código está disponible en mi repositorio de GitHub). Aun con esa selección, el ejercicio me sirvió muchísimo, y además descubrí cosas que ni siquiera me había imaginado antes de empezar, como el comportamiento en bucle de mi video más visto, o la diferencia entre qué tan corto es un video y qué tanto genera conversación en los comentarios.

Próximos pasos

Este proyecto no está cerrado. Conforme mi página siga generando nuevas publicaciones, puedo seguir alimentando la base de datos con esa información, agregar nuevas tablas si hace falta, y plantear consultas adicionales que hoy no se me han ocurrido.

También queda abierta la parte de Power BI: el siguiente paso natural es representar estas mismas tablas y consultas en dashboards visuales, para tener una forma más rápida y clara de consultar esta información en el día a día.

Gracias por tomarte el tiempo de leer este documento hasta el final.

Enlaces y proyectos relacionados

- Repositorio de **GitHub**: <https://github.com/Armandohernandezsayago>
- Perfil de **Linkedin**: <https://www.linkedin.com/in/armhersay13/>
- Página de **Facebook**: <https://www.facebook.com/share/1CVCXuomUo/?mibextid=wwXlfr>
- Página de **TikTok**: <https://www.tiktok.com/@sonido.los.puercos?>
proyecto futuro, aplicando un análisis similar pero usando Excel como herramienta principal en vez de SQL.